

## DATA WAREHOUSING e OLAP

Gabriel H. Schaeffer

### QUESTÕES

1) Já que um Data Warehouse (sistema OLAP - Online Analytical Processing) é utilizado por bem menos pessoas do que um sistema OLTP (Online Transaction Processing - um ERP, por exemplo) poderíamos investir menos dinheiro no hardware que suportaria um Data Warehouse afinal de contas o sistema será menos concorrido – utilizado por menos pessoas, somente a turma da análise de dados. Você concorda com essa afirmação? Justifique sua resposta.

Eu não concordo com essa afirmação. O dinheiro investido em hardware para suportar determinado sistema deve considerar não só o número de usuários, mas também (e com muito mais peso) a carga computacional deste.

Por exemplo, o volume de dados processados em uma Data Warehouse é significativamente maior do que em um sistema OLTP. Ou seja, mais hardware é necessário para concluir análises, transferências e demais operações com esta carga massiva de dados, quando comparado a um sistema OLTP.

2) Qual a necessidade afinal de possuímos um Data Warehouse já que a origem dos dados é o sistema OLTP em produção? Poderíamos ter um sistema único – o ERP – e extrair informações diretamente dele. Está certo esse raciocínio?

Tendo em mente o objetivo principal de um Data Warehousing, que é coletar dados para posterior análise que norteia a tomada de decisões empresariais, é possível perceber que ter um sistema único causaria uma insuficiência de dados, dificultando a análise destes e perda de performance.

Imagine um cenário onde um sistema único, que gera os dados, é usado para armazená-los também. O sistema apresentaria perdas de performance em sua tarefa principal, afinal agora ele precisa lidar com os dados também. Isso também implica que uma menor quantidade de dados poderia ser armazenada para posterior extração, numa tentativa de balancear as duas tarefas que o sistema agora precisa cumprir, causando a insuficiência de dados mencionada, visto que para uma análise suficiente dos dados, se mostra necessário uma extensa coleção destes.

3) Extract, Transform, Load são ações ou atividades periodicamente atreladas à alimentação de um Data Warehouse. Por que cada uma delas é importante?

**Extract:** É a etapa que coleta os dados de diversas fontes e junta em um lugar só. Importante para centralizar esses dados brutos, visto que as próximas etapas funcionam melhor com estes em um lugar só.

**Transform:** Muitas vezes, os dados extraídos estão nulos, em formatos diferentes, etc. Essa etapa é importante para limpar e padronizar os dados, garantindo que eles estão em conformidade entre si.

**Load:** É a etapa que disponibiliza os dados de forma organizada para análise. É importante, pois é necessário que eles estejam acessíveis para que a análise possa acontecer.

4) Por que a figura geométrica de um CUBO foi associada às operações de análise de dados realizadas em sistemas de Data Warehouse?

O cubo representa a capacidade de analisar dados sob múltiplas “dimensões” de análise (tempo, região, cliente, etc).

Além disso, sistemas OLAP usam estruturas de dados multidimensionais baseadas em matrizes chamadas de “cubos”, que possibilitam uma análise mais rápida e flexível em várias dimensões, evidenciando que realmente essa associação com a figura geométrica de um cubo existe, justamente por operar em várias dimensões.

5) Quais os tipos de conhecimento que você identifica como sendo necessários para uma pessoa ou uma equipe de pessoas trabalhar/rem com um sistema de Data Warehouse? Imagine que você tenha que contratar alguém. Quais conhecimentos e habilidades você exigiria?

Eu imagino que o profissional que trabalha em um sistema de Data Warehouse precisa ter conhecimento da “stack de dados”.

Primeiramente, ele precisaria ter noções de engenharia de dados. Como coletar dados e integrá-los em um único local. Ele precisa ser proficiente em SQL e entender como funcionam os sistemas da empresa.

Ademais, para a parte de Transform, ele precisa conhecer as ferramentas utilizadas para fazer isso. Uma delas seria a biblioteca Pandas da linguagem Python.

Por fim, para a parte de análise, é preciso de um profissional que conheça as ferramentas para analisar dados. Nesse contexto, é necessário alguém que consiga aplicar modelos de Machine Learning neles, o que implica conhecimentos matemáticos sobre os conceitos de ML e o conhecimento de bibliotecas em Python como scikit-learn, etc. Para a parte de gerar dashboards, espera-se que ele conheça ferramentas como matplotlib, ou até mesmo PowerBI.